




دانشگاه صنعتی خواجه نصیرالدین طوسی
دانشکده مهندسی برق

درس یادگیری ماشین مقدماتی گزارش پروژه پایانی

نام و نام خانوادگی	پوریا امیری
شماره دانشجویی	۴۰۱۱۵۹۷۳
تاریخ	مردادماه ۱۴۰۵
لینک گیت هاب	لینک



فهرست مطالب

۳	۱	مقدمه و بیان مسئله
۳	۲	معرفی مجموعه داده
۴	۳	پیش‌پردازش داده‌ها و مهندسی خط لوله
۴	۱.۳	آماده‌سازی پایه و بهینه‌سازی عملکرد
۴	۲.۳	غنی‌سازی داده‌ها (Data Augmentation)
۵	۳.۳	مدیریت ساختاری وزن کلاس‌ها
۵	۴	معماری مدل و دلیل انتخاب آن
۶	۵	جزئیات پیاده‌سازی و محیط اجرا
۶	۱.۵	مدیریت ساختاری عدم توازن با تابع Focal Loss
۷	۲.۵	بهینه‌سازی و فرایارامترها
۷	۳.۵	توابع بازخورد جهت کنترل آموزش
۷	۶	معیارهای ارزیابی
۷	۱.۶	ماتریس درهم‌ریختگی
۸	۲.۶	فرمول‌های ارزیابی
۹	۷	نتایج آزمایش‌ها
۹	۱.۷	مصورسازی و توضیح‌پذیری مدل (Grad-CAM)
۱۰	۸	تحلیل و مقایسه نتایج
۱۰	۹	توسعه نمونه اولیه و رابط کاربری بالینی
۱۱	۱۰	نقاط قوت و محدودیت‌های روش
۱۱	۱.۱۰	نقاط قوت
۱۱	۲.۱۰	محدودیت‌ها و چالش‌ها
۱۱	۱۱	نتیجه‌گیری و پیشنهاد برای کارهای آینده
۱۱	۱.۱۱	نتیجه‌گیری
۱۱	۲.۱۱	پیشنهاد برای کارهای آینده



چکیده

تشخیص به موقع و دقیق تومورهای مغزی نقش حیاتی در روند درمان و مراقبت از بیماران ایفا می کند. در روش های سنتی، بررسی تصاویر MRI توسط پزشکان یا رادیولوژیست ها انجام می شود که فرآیندی زمان بر، به شدت وابسته به تجربه و مستعد خطای انسانی در مواجهه با حجم انبوه داده های پزشکی است. هدف اصلی این پژوهش، طراحی و پیاده سازی یک سیستم طبقه بندی هوشمند مبتنی بر یادگیری عمیق برای دسته بندی تصاویر MRI مغز به چهار کلاس متمایز است: گلیوما (Glioma)، مننژیوما (Meningioma)، تومور هیپوفیز (Pituitary tumor) و حالت بدون تومور (No tumor).

این مدل به عنوان یک ابزار تریاژ و غربالگری اولیه عمل می کند؛ به این صورت که ابتدا به طور ضمنی وجود یا عدم وجود تومور را تشخیص داده و در صورت وجود، نوع پاتولوژی آن را مشخص می سازد. برای غلبه بر محدودیت های محاسباتی و زمانی، از رویکرد یادگیری انتقال (Transfer Learning) و معماری سبک اما قدرتمند EfficientNet-B0 بر روی مجموعه داده ای شامل تقریبی ۷۲۰۰ تصویر استفاده شد. همچنین برای مقابله با چالش رایج عدم توازن کلاس ها در مجموعه داده های پزشکی، از تکنیک های ساختاری شامل اعمال وزن دهی به کلاس ها (Class Weights) و استفاده از تابع زیان تخصصی (Focal Loss) بهره گرفته شد تا مدل به شکلی معنادار بر روی کلاس های در اقلیت تمرکز کند.

عملکرد مدل با استفاده از معیارهای استاندارد مانند دقت، امتیاز F1 و ماتریس درهم ریختگی ارزیابی گردید. علاوه بر این، به منظور ارائه یک ارزیابی بالینی معتبر و آکادمیک، از نمودارهای ویژگی عملکرد گیرنده چندکلاسه (Multi-class ROC) به روش One-vs-Rest و محاسبه سطح زیر نمودار (AUC) استفاده شد. نتایج آزمایش ها نشان دهنده دستیابی به دقت کلی ۷۵.۶۸ درصد پس از مرحله تنظیم دقیق (Fine-Tuning) است. به طور خاص، مدل در شناسایی کلاس "بدون تومور" به امتیاز AUC برابر با ۰.۹۸۶ دست یافت که نشان دهنده توانایی جداسازی بالینی تقریباً بی نقص و قابلیت اطمینان بالا برای فیلتر کردن تصاویر سالم است. در نهایت، به منظور افزایش شفافیت و قابلیت دفاع بالینی، از الگوریتم Grad-CAM برای مصورسازی نواحی تأثیرگذار در تصمیم گیری شبکه ی عصبی استفاده شد که توانست تقریب مناسبی از محل قرارگیری تومورها را ارائه دهد.



۱ مقدمه و بیان مسئله

تشخیص به موقع و دقیق تومورهای مغزی یکی از حیاتی ترین عوامل در افزایش شانس بقا، اتخاذ تصمیمات بالینی صحیح و بهبود روند درمان بیماران مبتلا به عارضه های عصبی است. در فرآیندهای بالینی و تشخیصی استاندارد، تصاویر MRI به دلیل وضوح بالا و توانایی در نمایش دقیق بافت های نرم، به عنوان ابزار اصلی برای بررسی ساختار مغز مورد استفاده قرار می گیرند. به طور سنتی، طی یک فرآیند معمول بررسی MRI، پزشکان متخصص و رادیولوژیست ها باید این تصاویر را به صورت چشمی مورد بازبینی قرار دهند تا در ابتدا وجود یا عدم وجود تومور را تشخیص داده و در گام بعدی، نوع دقیق تومور را شناسایی نمایند.

با این حال، این رویکرد تشخیصی سنتی با چالش ها و محدودیت های بالینی و عملیاتی اساسی روبرو است. بررسی دستی و تحلیل بصری حجم انبوهی از تصاویر پزشکی فرآیندی به شدت زمان بر است و میزان دقت آن وابستگی مستقیمی به سطح تجربه، مهارت و تخصص پزشک دارد. علاوه بر این، خستگی ناشی از بررسی های طولانی مدت و مواجهه روزانه با حجم عظیمی از داده های تصویری در مراکز درمانی، فرآیند تشخیص را به شدت مستعد خطای انسانی می سازد که می تواند به قیمت تأخیر در روند درمان تمام شود.

برای غلبه بر این محدودیت ها، هدف اصلی این پژوهش، طراحی، توسعه و پیاده سازی یک سیستم طبقه بندی هوشمند مبتنی بر شبکه های عصبی عمیق است که توانایی دسته بندی خودکار تصاویر MRI مغز را به چهار کلاس متمایز و کلیدی داشته باشد: گلیوما (Glioma)، مننژیوما (Meningioma)، تومور هیپوفیز (Pituitary tumor) و تصاویر سالم یا بدون تومور (No tumor).

منطق تصمیم گیری و ارزش آفرینی این مدل به گونه ای است که به عنوان یک ابزار غربالگری و تریاژ اولیه در محیط های بالینی عمل کند. سیستم در مواجهه با یک تصویر ورودی، ابتدا به صورت ضمنی وضعیت را از نظر "بدون تومور" بودن بررسی می کند. این قابلیت به مراکز درمانی اجازه می دهد تا اسکن های سالم را به سرعت فیلتر کرده و زمان ارزشمند رادیولوژیست ها را به بیماران پرخطر اختصاص دهند. در صورتی که سیستم وجود ناهنجاری و تومور را تشخیص دهد، به طور خودکار نوع دقیق پاتولوژی آن را در یکی از سه کلاس تومور دسته بندی می نماید. در نهایت، هدف از توسعه این پلتفرم هوش مصنوعی جایگزینی کادر درمان نیست، بلکه ارائه یک دستیار تصمیم گیری قابل اتکا، سریع و شفاف است که با تسریع فرآیند غربالگری اولیه و ارتقای ضریب اطمینان تشخیصی، به پزشکان در ارائه خدمات بهتر یاری رساند.

۲ معرفی مجموعه داده

مجموعه داده ی مورد استفاده در این پژوهش، شامل تصاویر MRI مغز است که به منظور آموزش و ارزیابی سیستم طبقه بندی هوشمند جمع آوری و سازماندهی شده اند. این مجموعه داده در مجموع شامل ۷۲۰۸ تصویر است که به صورت ساختار یافته به دو بخش اصلی تقسیم شده اند:

- داده های آموزشی (Training Set): شامل ۵۶۰۸ تصویر جهت آموزش و تنظیم پارامترهای مدل.
 - داده های آزمون (Testing Set): شامل ۱۶۰۰ تصویر جهت ارزیابی نهایی و سنجش میزان تعمیم پذیری مدل.
- تصاویر در چهار کلاس پاتولوژیک متمایز دسته بندی شده اند: گلیوما، مننژیوما، تومور هیپوفیز و تصاویر بدون تومور. تحلیل توزیع داده های آموزشی نشان می دهد که تعداد نمونه ها در کلاس های مختلف به شرح زیر است:

• گلیوما: ۱۴۰۰ تصویر

• مننژیوما: ۱۴۰۰ تصویر



• تومور هیپوفیز: ۱۴۰۱ تصویر

• بدون تومور: ۱۴۰۷ تصویر

اگرچه مجموعه داده‌های پزشکی در دنیای واقعی معمولاً با چالش عدم توازن شدید کلاس‌ها مواجه هستند، توزیع استخراج شده از این مجموعه داده نشان‌دهنده یک توازن تقریباً کامل میان کلاس‌ها است. این ویژگی، شرایط ایده‌آلی را برای فرآیند آموزش شبکه‌های عصبی فراهم می‌کند و خطر سوگیری مدل به سمت کلاس اکثریت را به حداقل می‌رساند.

۳ پیش‌پردازش داده‌ها و مهندسی خط لوله

پیش‌پردازش اصولی داده‌ها یکی از گام‌های بحرانی در موفقیت معماری‌های یادگیری عمیق است. در این پروژه، یک خط لوله کارآمد و مبتنی بر GPU برای آماده‌سازی و غنی‌سازی داده‌ها طراحی و پیاده‌سازی گردید. مراحل اصلی این فرآیند به شرح زیر است:

۱.۳ آماده‌سازی پایه و بهینه‌سازی عملکرد

در گام نخست، تمامی تصاویر ورودی به ابعاد استاندارد 224×224 پیکسل تغییر اندازه یافتند تا با الزامات ورودی معماری EfficientNet همخوانی داشته باشند. داده‌ها در دسته‌هایی با اندازه ۳۲ گروه‌بندی شدند. به منظور رفع گلوگاه‌های ورودی/خروجی و استفاده حداکثری از توان محاسباتی سخت‌افزار، از مکانیزم‌های tf.data.AUTOTUNE برای پیش‌بارگذاری (Prefetching) و پردازش موازی داده‌ها استفاده شد. نکته قابل توجه در این بخش، عدم اعمال نرمال‌سازی دستی (تقسیم مقادیر پیکسل‌ها بر ۲۵۵) است؛ زیرا معماری EfficientNet دارای یک لایه نرمال‌سازی درونی است که مستقیماً مقادیر خام پیکسل‌ها (در بازه ۰ تا ۲۵۵) را دریافت و پردازش می‌کند.

```

۱ IMG_SIZE = (224, 224)
۲ BATCH_SIZE = 32
۳ EPOCHS = 20
۴ LEARNING_RATE = 1e-4
۵
۶ AUTOTUNE = tf.data.AUTOTUNE
۷ train_dataset = train_dataset.map(
۸     lambda x, y: (data_augmentation(x, training=True), y),
۹     num_parallel_calls=AUTOTUNE
۱۰ ).prefetch(buffer_size=AUTOTUNE)
۱۱
۱۲ val_dataset = val_dataset.prefetch(buffer_size=AUTOTUNE)

```

۲.۳ غنی‌سازی داده‌ها (Data Augmentation)

با وجود حجم مناسب داده‌های آموزشی، شبکه‌های عصبی عمیق همواره در معرض خطر بیش‌برازش قرار دارند. برای مقابله با این پدیده و افزایش تنوع فضایی داده‌ها، یک ماژول غنی‌سازی داده به صورت پویا با استفاده از لایه‌های ترتیبی کراس (tf.keras.Sequential) پیاده‌سازی شد. این ماژول در هر دور آموزش (Epoch)، تغییرات تصادفی زیر را بر روی تصاویر اعمال می‌کند:



- قرینه‌سازی افقی تصادفی (Random Horizontal Flip)
- چرخش تصادفی تا حداکثر ۱۰ درصد (Random Rotation)
- بزرگ‌نمایی تصادفی تا حداکثر ۱۰ درصد (Random Zoom)
- تغییرات تصادفی در روشنایی تا حداکثر ۱۰ درصد (Random Brightness)

```

۱ data_augmentation = tf.keras.Sequential([
۲     layers.RandomFlip("horizontal"),
۳     layers.RandomRotation(0.1),
۴     layers.RandomZoom(0.1),
۵     layers.RandomBrightness(0.1),])

```

۳.۳ مدیریت ساختاری وزن کلاس‌ها

علیرغم توازن ایده‌آل مشاهدات در این مجموعه داده، به منظور حفظ جامعیت علمی و ایجاد آمادگی مدل برای مواجهه با داده‌های نامتوازن در محیط‌های بالینی واقعی، مکانیزم محاسبه و اعمال وزن کلاس‌ها پیاده‌سازی شد. وزن هر کلاس با استفاده از رابطه ریاضی زیر محاسبه گردید:

$$W_i = \frac{N}{C \times N_i} \quad (۱)$$

که در آن N کل نمونه‌های آموزشی (۵۶۰۸)، C تعداد کلاس‌ها (۴) و N_i تعداد نمونه‌های کلاس i است. نتایج محاسبات نشان داد که ضریب وزنی کلاس بدون تومور برابر با ۹۹۶.۰ و سایر کلاس‌ها در حدود ۰.۱۰۱ است. این مقادیر به صورت پارامتریک در تابع زیان شبکه تزریق شدند تا اطمینان حاصل شود مدل هیچ‌گونه سوگیری محاسباتی نخواهد داشت.

```

۱ num_classes = len(classes)
۲ class_weights_dict = {}
۳
۴ for i, c in enumerate(classes):
۵     weight = total_samples / (num_classes * class_counts[c])
۶     class_weights_dict[i] = weight

```

۴ معماری مدل و دلیل انتخاب آن

آموزش شبکه‌های عصبی پیچیده‌ی CNN از پایه، نیازمند حجم عظیمی از داده‌های برجسب‌دار و توان محاسباتی بسیار بالاست که در حوزه تصویربرداری پزشکی همواره یک چالش محسوب می‌شود. برای غلبه بر این محدودیت، در این پژوهش از رویکرد یادگیری انتقالی با بهره‌گیری از معماری پیش‌آموزش‌یافته‌ی EfficientNet-B0 استفاده شده است.

دلیل اصلی انتخاب EfficientNet-B0، ایجاد تعادل بهینه میان دقت بالا و بهره‌وری محاسباتی است. برخلاف معماری‌های سنگینی مانند ResNet یا VGG، خانواده EfficientNet از یک استراتژی مقیاس‌پذیری مرکب استفاده می‌کند که ابعاد شبکه را به شکلی متناسب



و بهینه گسترش می دهد. این ویژگی باعث می شود مدل بتواند با تعداد پارامترهای بسیار کمتر، عملکردی هم تراز یا بهتر از شبکه های سنگین تر ارائه دهد. خط لوله طراحی شده در این پروژه از اجزای زیر تشکیل شده است:

- لایه ورودی و غنی سازی: شبکه تصاویری با ابعاد $224 \times 224 \times 3$ را دریافت می کند. لایه غنی سازی داده ها مستقیماً در داخل مدل تعبیه شده است تا با شتاب دهی سخت افزاری اعمال شوند. همچنین شبکه دارای لایه نرمال سازی درونی است که نیاز به مقیاس بندی دستی را مرتفع می سازد.
- استخراج گر ویژگی: در فاز نخست آموزش، وزن های پایه مدل که بر روی دادگان ImageNet آموزش دیده اند، به حالت غیرقابل آموزش درآمده اند. این امر تضمین می کند که فیلترهای پایه شبکه در حین آموزش اولیه تخریب نشوند.
- لایه ادغام سراسری: برای کاهش ابعاد فضایی نقشه های ویژگی و تبدیل آن ها به یک بردار یک بعدی فشرده، از لایه GlobalAveragePooling2D استفاده شده است.
- تنظیم گر: برای کاهش خطر بیش پرازش، یک لایه Dropout با نرخ خاموش سازی ۰.۵ به معماری اضافه شده است.
- لایه طبقه بند نهایی: یک لایه متراکم با ۴ نورون و تابع فعال ساز Softmax قرار گرفته است که وظیفه محاسبه احتمال تعلق تصویر ورودی به هر کلاس را بر عهده دارد.

۵ جزئیات پیاده سازی و محیط اجرا

موفقیت مدل های یادگیری عمیق وابستگی مستقیمی به تنظیمات بهینه ساز، توابع زیان و مدیریت فرآیند آموزش دارد. این پروژه در محیط Google Colab با بهره گیری از GPU پیاده سازی شده است.

```

۱ base_model = applications.EfficientNetB0(
۲ input_shape=(*IMG_SIZE, 3),
۳ include_top=False,
۴ weights='imagenet')

```

۱.۵ مدیریت ساختاری عدم توازن با تابع Focal Loss

یکی از برجسته ترین نقاط قوت در پیاده سازی این سیستم، جایگزینی تابع زیان استاندارد با تابع زیان کانونی (Categorical Focal Crossentropy) است. در دادگان پزشکی، مدل ها معمولاً تمایل دارند بر روی نمونه های ساده تر تمرکز کنند. تابع Focal Loss این مشکل را با تخصیص وزن پویا به خطاها برطرف می کند؛ به این معنا که جریمه خطای پیش بینی برای نمونه های سخت به شدت افزایش و برای نمونه های ساده کاهش می یابد. این تابع با ساختار ریاضی زیر مدل سازی شده است:

$$FL(p_t) = -\alpha_t(1 - p_t)^\gamma \log(p_t) \quad (2)$$

در این پیکربندی، ضریب تمرکز ($\gamma = 2.0$) تنظیم شده است تا توجه شبکه به سمت داده های دشوارتر جلب شود و پارامتر متعادل کننده ($\alpha = 0.25$) تعیین گردید. علاوه بر این، در حلقه آموزش، دیکشنری وزن کلاس ها به صورت مستقیم به مدل تزریق شد تا رویکردی قدرتمند برای جبران هرگونه سوگیری ایجاد شود.



```
۱ focal_loss = tf.keras.losses.CategoricalFocalCrossentropy(alpha=0.25, gamma=2.0)
۲
۳ model.compile(
۴     optimizer=tf.keras.optimizers.Adam(learning_rate=LEARNING_RATE),
۵     loss=focal_loss,
۶     metrics=['accuracy'])
```

۲.۵ بهینه‌ساز و فرایارامتراها

الگوریتم بهینه‌ساز از نوع پیشرفته Adam انتخاب شد که در تنظیم نرخ یادگیری بسیار کارآمد است. برای فاز نخست آموزش، نرخ یادگیری بر روی مقدار محتاطانه 1×10^{-4} تنظیم گردید. مدل در دسته‌هایی با اندازه ۳۲ و برای حداکثر ۲۰ دوره پیکربندی شد.

۳.۵ توابع بازخورد جهت کنترل آموزش

برای مدیریت هوشمندانه فرآیند آموزش دو مکانیزم کنترلی حیاتی پیاده‌سازی شدند:

۱. توقف زودهنگام (Early Stopping): در صورتی که مدل به مدت ۵ دوره متوالی هیچ بهبودی در کاهش خطای داده‌های آزمون نشان ندهد، فرآیند آموزش متوقف شده و وزن‌های بهترین دوره بازیابی می‌شوند.
۲. ذخیره‌سازی نقاط کنترلی (Model Checkpoint): این تابع تنها مدلی را که بالاترین دقت اعتبارسنجی را کسب کرده است، در قالب استاندارد keras ذخیره می‌نماید. استفاده از این فرمت تضمین می‌کند که تمامی لایه‌های سفارشی بدون خطاهای رایج ثبت و نگهداری شوند.

۶ معیارهای ارزیابی

ارزیابی عملکرد مدل‌های یادگیری عمیق در حوزه‌های پزشکی نیازمند رویکردی چندبعدی است. تکیه صرف بر معیار دقت می‌تواند گمراه‌کننده باشد؛ به‌ویژه زمانی که هزینه تشخیص اشتباه بسیار بالا باشد. به همین دلیل، از مجموعه‌ای از معیارهای آماری استاندارد مبتنی بر ماتریس درهم‌ریختگی استفاده شده است.

۱.۶ ماتریس درهم‌ریختگی

ماتریس درهم‌ریختگی ابزاری بصری و تحلیلی است که عملکرد مدل را در تفکیک کلاس‌های مختلف نشان می‌دهد. ردیف‌ها نشان‌دهنده مقادیر واقعی و ستون‌ها نشان‌دهنده پیش‌بینی‌های مدل هستند. بر اساس این ماتریس، پارامترهای زیر استخراج می‌شوند:

- مثبت صحیح (TP): نمونه‌هایی که به درستی در کلاس هدف پیش‌بینی شده‌اند.
- منفی صحیح (TN): نمونه‌هایی که به درستی خارج از کلاس هدف پیش‌بینی شده‌اند.
- مثبت کاذب (FP): نمونه‌هایی که به اشتباه در کلاس هدف دسته‌بندی شده‌اند.



- منفی کاذب (FN): نمونه‌هایی که متعلق به کلاس هدف بوده‌اند اما مدل آن‌ها را تشخیص نداده است.

```

۱ y_true = []
۲ y_pred_probs = []
۳
۴ # Iterate through the validation dataset
۵ for images, labels in val_dataset:
۶     y_true.extend(np.argmax(labels.numpy(), axis=1))
۷     predictions = model.predict(images, verbose=0)
۸     y_pred_probs.extend(predictions)
۹
۱۰ y_true = np.array(y_true)
۱۱ y_pred = np.argmax(y_pred_probs, axis=1)
۱۲
۱۳ cm = confusion_matrix(y_true, y_pred)
۱۴
۱۵ plt.figure(figsize=(8, 6))
۱۶ sns.heatmap(cm, annot=True, fmt='d', cmap='Blues',
۱۷ xticklabels=class_names, yticklabels=class_names)

```



شکل ۱: خروجی ماتریس درهم‌ریختگی

۲.۶ فرمول‌های ارزیابی

دقت کل (Accuracy): نشان‌دهنده نسبت کل پیش‌بینی‌های صحیح به کل داده‌های ارزیابی است.

$$Accuracy = \frac{TP + TN}{TP + TN + FP + FN} \quad (۳)$$

دقت معیار (Precision): نشان می‌دهد از میان تمامی نمونه‌هایی که مدل به عنوان یک کلاس خاص پیش‌بینی کرده، چه نسبتی واقعاً متعلق به آن کلاس بوده‌اند.

$$Precision = \frac{TP}{TP + FP} \quad (۴)$$



فراخوانی (Recall): نشان می‌دهد مدل توانسته است چه نسبتی از نمونه‌های واقعی یک کلاس را به درستی شناسایی کند.

$$Recall = \frac{TP}{TP + FN} \quad (5)$$

امتیاز اف-۱: میانگین همساز بین Precision و Recall است و بهترین شاخص برای ارزیابی پایداری مدل در شرایط پیچیده به شمار می‌رود.

$$F1-Score = 2 \times \frac{Precision \times Recall}{Precision + Recall} \quad (6)$$

در این پژوهش، از کتابخانه scikit-learn برای محاسبه و استخراج خودکار این معیارها استفاده گردید.

```
Evaluating model on the test dataset...
Test Accuracy: 0.7800
Test Loss: 0.0722

Classification Report:

```

	precision	recall	f1-score	support
glioma	0.84	0.54	0.66	400
meningioma	0.70	0.62	0.66	400
notumor	0.88	0.97	0.92	400
pituitary	0.72	0.99	0.84	400
accuracy			0.78	1600
macro avg	0.79	0.78	0.77	1600
weighted avg	0.79	0.78	0.77	1600


شکل ۲: خروجی ارزیابی

۷ نتایج آزمایش‌ها

در این بخش، نتایج ارزیابی مدل طبقه‌بند پس از طی فازهای آموزش اولیه و تنظیم دقیق ارائه می‌شود. با اعمال رویکردهای مقابله با عدم توازن داده‌ها، مدل به دقت کلی ۷۵.۶۸ درصد بر روی مجموعه داده‌های آزمون دست یافت. به منظور ارائه یک ارزیابی استاندارد، از نمودار ویژگی عملکرد گیرنده چندکلاسه با استراتژی One-vs-Rest استفاده شد.

۱.۷ مصورسازی و توضیح‌پذیری مدل (Grad-CAM)

علاوه بر ارزیابی‌های کمی، الگوریتم نقشه فعال‌سازی کلاس مبتنی بر گرادیان (Grad-CAM) پیاده‌سازی گردید. برای جلوگیری از خطاهای رایج قطع ارتباط گراف، این ماژول با استفاده از تکنیک اجرای مشتاقانه (Eager Execution) توسعه یافت. در این فرآیند، نقشه ویژگی از آخرین لایه کانولوشنی استخراج شده و گرادیان‌های کلاس برنده محاسبه می‌شوند. در نهایت، یک نقشه حرارتی تولید شده و بر روی تصویر اصلی MRI ادغام می‌گردد تا مناطقی که بیشترین تأثیر را داشته‌اند، برجسته شوند.



شکل ۳: نمونه خروجی تصویری

۸ تحلیل و مقایسه نتایج

تحلیل جامع نتایج نشان می‌دهد که مدل با موفقیت به اهداف بالینی پروژه دست یافته است:

- عملکرد عالی در تریاژ پزشکی: کسب امتیاز AUC برابر با ۰.۹۸۶ برای کلاس "بدون تومور" توانایی جداسازی بالینی تقریباً بی نقص این سیستم را نشان می‌دهد. این عدد اثبات می‌کند که مدل می‌تواند اسکن‌های سالم را فیلتر کرده و زمان رادیولوژیست‌ها را ذخیره نماید.
- تأثیر مهندسی توابع زیان: دستیابی به امتیازهای AUC بالای ۰.۸۷ برای کلاس‌های مننژیوما و گلیوما، اثربخشی استفاده از تابع زیان کانونی و وزن‌دهی کلاس‌ها را تأیید می‌کند. شبکه موفق شد تفاوت‌های بافتی ظریف تومورهای دشوار را یاد بگیرد.
- اعتبارسنجی بالینی از طریق XAI: نقشه‌های حرارتی Grad-CAM نشان می‌دهد که مدل تصمیمات خود را بر اساس نواحی پس‌زمینه اتخاذ نمی‌کند. این نواحی مستقیماً بر روی توده تومور متمرکز شده‌اند و ثابت می‌کند منطق تصمیم‌گیری مدل با استدلال‌های پزشکی همسو است.

۹ توسعه نمونه اولیه و رابط کاربری بالینی

به منظور ارزیابی کاربردپذیری مدل در محیط‌های واقعی، یک نمونه اولیه تعاملی با استفاده از کتابخانه Gradio توسعه یافت. این رابط کاربری، فرآیند استخراج و تولید نقشه‌های حرارتی را در قالب یک داشبورد ساده پنهان می‌کند. در پیاده‌سازی این ماژول، تمهیدات پیش‌پردازشی سخت‌گیرانه‌ای اعمال شد تا از بروز خطاهای تطابق داده‌ها جلوگیری شود. کاربر با بارگذاری تصویر خام MRI، احتمالات دسته‌بندی و خروجی Grad-CAM را مشاهده می‌نماید.



۱۰ نقاط قوت و محدودیت‌های روش

۱.۱۰ نقاط قوت

- قابلیت اطمینان در غربالگری: امتیاز AUC نزدیک به یک برای کلاس «بدون تومور»، سیستم را به ابزاری قدرتمند برای تریاژ تبدیل کرده است.
- مدیریت ساختاری عدم توازن داده‌ها: استفاده همزمان از وزن‌دهی کلاس‌ها و تابع زیان کانونی به صورت ریاضیاتی با سوگیری مقابله کرد.
- شفافیت تصمیم‌گیری: استفاده از Grad-CAM مدل را از حالت جعبه سیاه خارج کرده است.
- کاربرپذیری: داشبورد تحت وب قابلیت ادغام سیستم در نرم‌افزارهای بیمارستانی را نشان می‌دهد.

۲.۱۰ محدودیت‌ها و چالش‌ها

- حساسیت به داده‌های خارج از توزیع: تصاویری با آرتیفکت‌های شدید یا زوایای متفاوت می‌توانند باعث افت عملکرد شوند.
- محدودیت در تقطیع (Segmentation): سیستم قادر به ترسیم مرزهای دقیق پاتولوژی برای جراحی نیست.
- هزینه محاسباتی: اجرای همزمان استنتاج و استخراج گرادیان در صورت عدم دسترسی به سخت‌افزار مناسب می‌تواند با تأخیر همراه باشد.

۱۱ نتیجه‌گیری و پیشنهاد برای کارهای آینده

۱.۱۱ نتیجه‌گیری

این پژوهش با موفقیت یک سیستم طبقه‌بندی هوشمند را برای تشخیص تومورهای مغزی طراحی، پیاده‌سازی و ارزیابی نمود. سیستم با مقابله‌ی ساختاریافته با چالش‌های دادگان، به ابزاری قابل اتکا تبدیل شده است. یادگیری انتقال با معماری EfficientNet-B0 بهینه‌سازی منابع محاسباتی را تضمین کرد و استفاده از تابع زیان کانونی بر مشکل سوگیری کلاس‌ها غلبه نمود. کسب امتیاز AUC برابر با ۰.۹۸۶ برای اسکن‌های سالم، ظرفیت بالای آن را به عنوان ابزار غربالگری اثبات کرد. در نهایت، ادغام الگوریتم Grad-CAM و رابط کاربری تحت وب، این پژوهش را به یک نمونه اولیه بالینی شفاف و قابل دفاع ارتقا داد.

۲.۱۱ پیشنهاد برای کارهای آینده

جهت ارتقای عملکرد در آینده، موارد زیر پیشنهاد می‌گردد:

۱. یادگیری تجمیعی: آموزش موازی مدل‌های دیگری نظیر ResNet50 و ترکیب خروجی آن‌ها برای پوشش خطاهای فردی.



۲. گسترش به تقطیع معنایی (Semantic Segmentation): بهره‌گیری از معماری‌هایی نظیر U-Net برای تعیین مرزهای دقیق تومور و محاسبه حجم سه‌بعدی توده.
۳. ارتقای تعمیم‌پذیری: تنظیم دقیق مدل بر روی مجموعه داده‌های چندمرکزی با پروتکل‌های تصویربرداری متفاوت.
۴. ارزیابی بالینی: استقرار داشبورد در محیط بیمارستانی کنترل‌شده جهت جمع‌آوری بازخورد مستقیم از رادیولوژیست‌ها.